Análisis y clasificación de riesgo sísmico

Santander, Colombia (1993 - 2026)

Explicación del proceso: limpieza de datos, exploración, modelo de Machine Learning y dashboard en Power BI

Archivo	Qué contiene
Fuente	Servicio Geológico Colombiano (SGC) - https://www.sgc.gov.co/sismos
limpieza_datos.py	Script que filtra, selecciona variables y crea la variable objetivo **nivel_riesgo**.
reto1.ipynb	Notebook con diccionario de variables, exploración, correlaciones y modelo Random Forest.
sismos_pbix.zip	Proyecto de Power BI (.pbix) con un mapa de sismos, una tarjeta por nivel de riesgo y un filtro por lugar.

1. Resumen del proyecto

El proyecto parte de un catálogo de sismos de la región de Santander (Colombia). El objetivo es clasificar cada sismo en un **nivel de riesgo (Bajo, Medio o Alto)** y visualizar los resultados en un dashboard. El flujo de trabajo tiene tres etapas:

- **Limpieza (Python):** se conservan solo los registros revisados manualmente, se eligen 12 variables y se crea el nivel de riesgo.
- **Modelado (Jupyter):** se explora el dataset de 214.833 sismos y se entrena un Random Forest para predecir el nivel de riesgo.
- **Visualización (Power BI):** un mapa geográfico y filtros permiten explorar los sismos por riesgo y lugar.

Fuente de los datos

Los datos provienen del **Servicio Geológico Colombiano (SGC)**, a través de su portal de sismos (https://www.sgc.gov.co/sismos). Los sismos los registra la **Red Sismológica Nacional de Colombia (RSNC)**, que opera el SGC y que mantiene el registro de sismicidad desde junio de 1993, fecha que coincide con el primer registro del dataset.

- **Acceso:** la información de la RSNC es pública, y el SGC ofrece un catálogo de sismicidad consultable por fechas, zona y magnitud.
- **Magnitud:** los boletines del SGC usan la magnitud local MLr, calibrada para Colombia (Rengifo y Ojeda, 2004).
- **Hora:** según los boletines, la hora local de Colombia se obtiene restando 5 horas a la hora UTC.
- **Filtro regional:** el catálogo cubre todo el país; este proyecto se centra en Santander.

Nota sobre la hora: en el dataset, *local_time* aparece con el sufijo "+00:00" (por ejemplo 2026-10-09T09:25:19+00:00). Ese sufijo indica UTC, así que conviene verificar si la columna realmente está en hora local colombiana (UTC-5) o en UTC, antes de hacer análisis por hora del día.

2. Limpieza de datos (limpieza_datos.py)

El script lee el archivo original *sismos.csv* y genera *sismos_santander_procesado.csv* en siete pasos:

Paso	Qué hace	Por qué
1	Carga el dataset original con pandas e imprime el total de registros.	Punto de partida y control del volumen inicial.
2	Filtra **status == "manual"**.	Los registros revisados manualmente tienen mayor confiabilidad técnica que los automáticos.
3	Selecciona 12 columnas: magnitude, depth, latitude, longitude, rms, gap, nst, magnitude_error, depth_error, latitude_error, longitude_error, local_time.	Se conservan las variables físicas y de calidad de la medición.
4	Elimina filas con nulos en magnitude, depth, latitude o longitude.	Son las variables físicas críticas; sin ellas el registro no sirve.
5	Crea la variable objetivo **nivel_riesgo** con la regla de abajo.	Convierte el problema en una clasificación supervisada.

Paso	Qué hace	Por qué
6	Imprime el porcentaje de cada clase.	Verifica el balance de clases.
7	Guarda el CSV procesado.	Queda listo para el modelado.

Regla para el nivel de riesgo

El criterio combina magnitud y profundidad: los sismos más energéticos y los superficiales se consideran más peligrosos.

Nivel	Condición
Alto	magnitud >= 4.0, **o** (magnitud >= 3.0 y profundidad < 30 km)
Medio	magnitud >= 2.5 (y no cumple la condición de Alto)
Bajo	magnitud < 2.5

Código de la regla:

```
def assign_risk(row):
    mag = row["magnitude"]; dep = row["depth"]
    if mag >= 4.0 or (mag >= 3.0 and dep < 30): return "Alto"
    elif mag >= 2.5: return "Medio"
    else: return "Bajo"
```

3. Diccionario de variables

El dataset procesado tiene **214.833 sismos** y **13 columnas**, registrados entre 1993 y 2026. Cada fila es un sismo.

Variable	Descripción	Tipo
magnitude	Magnitud del sismo.	float
depth	Profundidad del sismo, en km.	int
latitude	Latitud del epicentro, en grados.	float
longitude	Longitud del epicentro, en grados.	float
rms	Error promedio de los tiempos de llegada de las ondas (segundos). Menor es mejor.	float
gap	Mayor hueco angular (0-360°) entre las estaciones que lo detectaron. Menor es mejor.	float
nst	Número de estaciones sísmicas que registraron el sismo.	int
magnitude_error	Incertidumbre de la magnitud.	float
depth_error	Incertidumbre de la profundidad (km).	float
latitude_error	Incertidumbre de la latitud (km).	float
longitude_error	Incertidumbre de la longitud (km).	float
local_time	Fecha y hora del sismo.	texto

Variable	Descripción	Tipo
nivel_riesgo	Clasificación de riesgo: Bajo, Medio o Alto (variable objetivo).	texto

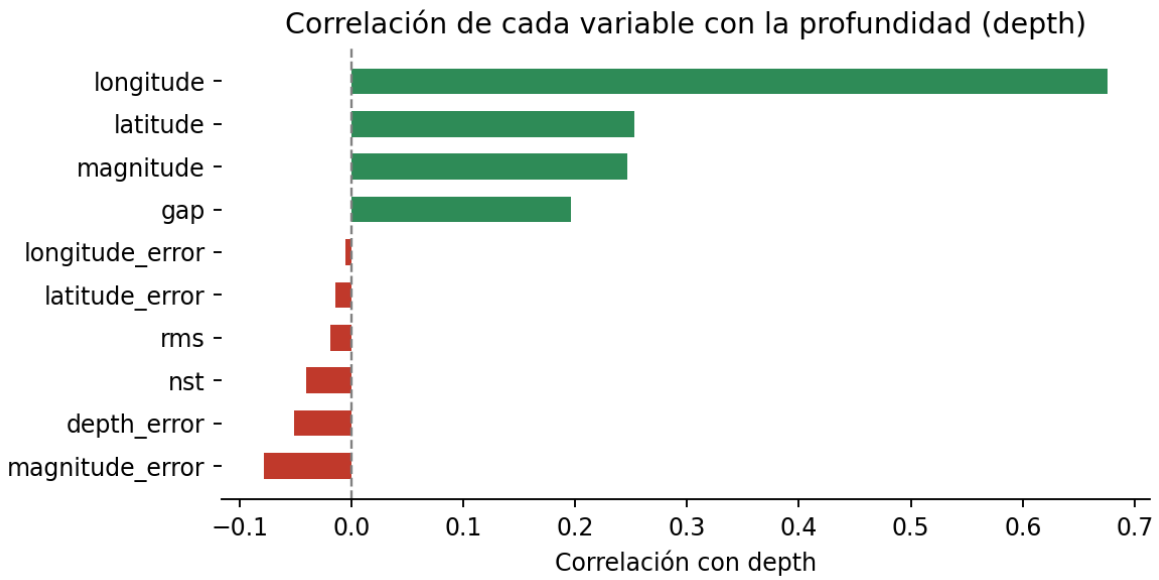
4. Exploración de datos

Con `head()`, `tail()` e `info()` se revisó la estructura del dataset. Hallazgos principales:

- El dataset va de 1993-06-01 a 2026-10-09, con los registros más recientes primero.
- Las columnas principales no tienen nulos. Sí hay nulos en **magnitude_error** (solo 105.629 de 214.833 registros con dato, es decir ~49%), **depth_error** (270 nulos), **gap** (9 nulos) y **latitude_error/longitude_error** (11 nulos cada una).
- La profundidad máxima es **436 km** y la mínima **-5 km**. Un valor negativo indica que el hipocentro quedó calculado por encima del nivel de referencia, algo que conviene revisar o documentar.
- Los sismos más recientes se concentran alrededor de latitud 6.7-6.9 y longitud -73.1 a -73.2, con profundidades de 140-160 km.

5. Correlaciones con la profundidad

Se calculó la correlación de cada variable numérica con **depth** para ver cuál la predice mejor. La longitud es la más fuerte (+0.676), seguida de lejos por latitud (+0.253), magnitud (+0.247) y gap (+0.196). El resto casi no se relaciona con la profundidad.

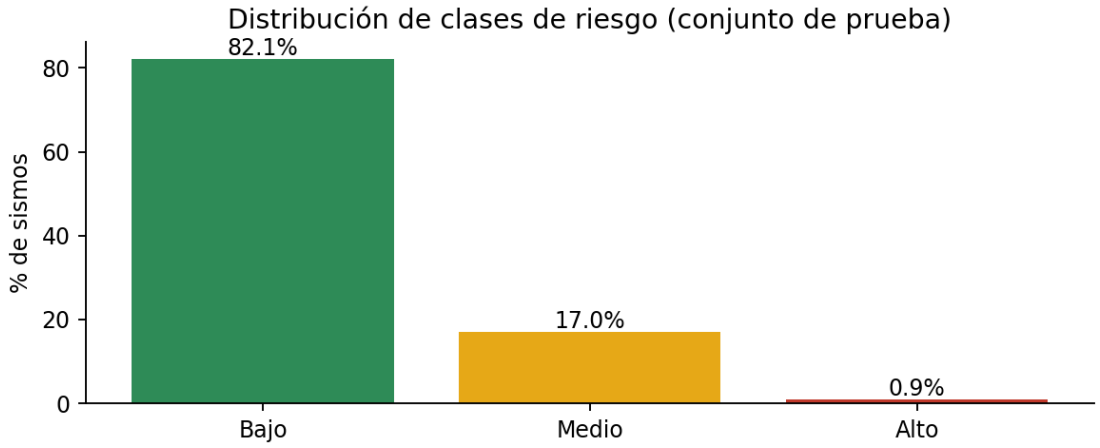


Interpretación: la relación con la longitud tiene sentido geológico, porque la profundidad de los sismos cambia a medida que se avanza en dirección este-oeste a lo largo de la zona de subducción. Las variables de error (rms, *_error, nst) prácticamente no se relacionan con la profundidad.

6. Modelo de clasificación

Se entrenó un **Random Forest** para predecir *nivel_riesgo*.

Elemento	Configuración
Variables de entrada (11)	magnitude, depth, latitude, longitude, rms, gap, nst, magnitude_error, depth_error, latitude_error, longitude_error
Nulos	Se rellenan con 0 (`fillna(0)`).
Variable objetivo	nivel_riesgo (Bajo / Medio / Alto)
División	80% entrenamiento (171.866) / 20% prueba (42.967), con `stratify=y` para mantener las proporciones de clases y `random_state=42`.
Algoritmo	RandomForestClassifier(n_estimators=100, max_depth=10, random_state=42)



Las clases están muy desbalanceadas: la mayoría de los sismos son de riesgo Bajo y solo cerca del 1% son de riesgo Alto.

Resultados en el conjunto de prueba

Exactitud (accuracy): 0.9998. Matriz de confusión (filas = real, columnas = predicho):

Real \ Predicho	Alto	Bajo	Medio
Alto	382	0	9
Bajo	0	35.257	0
Medio	0	0	7.319

Clase	Precision	Recall	F1-score	Soporte
Alto	1.00	0.98	0.99	391
Bajo	1.00	1.00	1.00	35.257
Medio	1.00	1.00	1.00	7.319
Total / promedio	1.00	0.99 (macro)	1.00	42.967

El modelo solo se equivoca en 9 sismos de riesgo Alto que clasificó como Medio. En todo lo demás acierta.

Importante - por qué el resultado es casi perfecto: la variable *nivel_riesgo* se construyó a partir de **magnitude** y **depth**, y esas mismas dos columnas se usaron como variables de entrada del modelo. Por eso

el Random Forest no está "prediciendo" el riesgo, sino reaprendiendo la regla del script de limpieza (fuga de datos o *data leakage*). El 99,98% de exactitud no demuestra que el modelo sirva para anticipar riesgo en situaciones reales. Para un modelo realmente predictivo habría que quitar magnitude y depth de las entradas, o definir el riesgo con criterios externos.

7. Dashboard en Power BI

El archivo *sismos_pbix.zip* contiene un proyecto de Power BI con una sola página (1280 x 720 px) que usa una tabla llamada **df_clean**. Sus elementos son:

Elemento	Datos que usa	Función
Mapa	longitude, latitude, conteo de magnitude, nivel_riesgo	Ubica cada sismo geográficamente, con el color según el nivel de riesgo.
Tarjeta (card)	nivel_riesgo	Muestra el indicador por nivel de riesgo.
Segmentador (slicer)	place	Filtra por lugar; está configurado en "Bucaramanga - Santander, Colombia".
Botón de acción	-	Botón de regreso (icono "back") en la esquina superior izquierda.

Observaciones sobre el dashboard

- La tabla **df_clean** incluye la columna **place**, que no está en el CSV generado por limpieza_datos.py (ese script solo conserva 12 columnas más nivel_riesgo). Esto indica que el dashboard se alimentó con una versión del dataset que conserva la columna de lugar, o que se cargó antes de recortar las columnas.
- El modelo de datos pesa unos 35 MB, lo que concuerda con el volumen de más de 200.000 registros.
- El dashboard solo muestra información descriptiva; no incluye todavía las predicciones del modelo ni gráficos de tendencia en el tiempo (por ejemplo, sismos por año con *local_time*).

8. Conclusiones y siguientes pasos

- El pipeline completo está armado: limpieza, exploración, modelo y visualización.
- El filtro por registros manuales mejora la confiabilidad, pero reduce el volumen respecto al dataset original.
- La clase **Alto** es muy escasa (~1% de los datos); conviene vigilar métricas por clase y no solo la exactitud global.
- **Corregir la fuga de datos** antes de presentar el modelo: entrenar sin magnitude y depth, o definir el riesgo con otro criterio.
- Revisar las profundidades negativas (mínimo -5 km) y decidir si se corrigen o se documentan.
- Conectar al dashboard las predicciones y agregar una vista temporal usando local_time.